

## Lista 3 - Otimização Não Linear Inteira Mista COS886 - 2021/3

Amanda Ferreira de Azevedo - afazevedo@cos.ufrj.br

PESC/UFRJ — 28 de janeiro de 2022

### Exercício 4.1

Considere o problema de otimização:

$$\begin{array}{ll}\min & f_0(x_1, x_2) \\ \text{s.a.} & 2x_1 + x_2 \geq 1 \\ & x_1 + 3x_2 \geq 1 \\ & x \geq 0\end{array}$$

Faça um desenho e apresente a região viável e duas curvas de nível para a função objetivo do problema. Para cada função objetivo, determine o conjunto ótimo e o valor ótimo da função objetivo, a partir do gráfico.

1.  $f_0(x_1, x_2) = x_1 + x_2$ .
2.  $f_0(x_1, x_2) = -x_1 - x_2$ .
3.  $f_0(x_1, x_2) = x_1$ .
4.  $f_0(x_1, x_2) = \max\{x_1, x_2\}$ .
5.  $f_0(x_1, x_2) = x_1^2 + 9x_2^2$ .

O conjunto de restrições nos dá a região viável delimitada por  $(0, \infty)$ ,  $(0, 1)$ ,  $(2/5, 1/5)$ ,  $(1, 0)$ ,  $(\infty, 0)$ , como mostra a Figura 1.





Figura 1: Região viável


$$f_0(x_1, x_2) = x_1 + x_2$$

As curvas de nível são definidas pelo conjunto  $\{x_1, x_2 \mid x_1 + x_2 = C\}$ . Como o problema é de minimização, então a direção da solução ótima será oposta ao gradiente. Neste caso,  $\nabla f(x) = (1, 1)$  e a curva de nível  $x + y = 0.6$  bate exatamente no ponto  $x^* = (2/5, 1/5)$ , que é perpendicular a esta curva.



$$f_0(x_1, x_2) = -x_1 - x_2$$

As curvas de nível são definidas pelo conjunto  $\{x_1, x_2 \mid x_1 + x_2 = C\}$ . Como o problema é de minimização, então a direção da solução ótima será oposta ao gradiente. Neste caso,  $\nabla f(x) = (-1, -1)$  e as curvas de nível não encontrarão nenhum ponto, pois a região é ilimitada para este lado.



$$f_0(x_1, x_2) = x_1.$$

Observando a Figura ??, basta encontrarmos o menor valor que  $x_1$  pode assumir na região viável. Esta solução é atingida exatamente quando  $x_1 = 0$  e  $x_2 \geq 1$ , uma vez que a função objetivo independe do valor de  $x_2$ .


$$f_0(x_1, x_2) = \max\{x_1, x_2\}.$$

Suponha que  $x_1 > x_2$ . Teremos a mesma função objetivo do item anterior. No entanto, não podemos tomar  $x_1 = 0$ , uma vez que  $x_2 \geq 1/5$  e  $x_1 > x_2$ . Dessa forma,  $x_1 > 1/5$ .

De forma análoga, se tomarmos  $x_2 > x_1$ , vamos minimizar  $x_2$  e  $x_2 > 2/5$ , pois  $x_1 \geq 2/5$ .


Se  $x_1 = x_2$ , o menor valor é atingido no ponto  $x^* = (1/3, 1/3)$ .

Dessa forma, o menor valor que a função objetivo pode atingir é exatamente no caso em que  $x_1 = x_2$ .



$$f_0(x_1, x_2) = x_1^2 + 9x_2^2.$$

Observe que podemos trocar a função objetivo por  $x_1 + 3x_2$ , uma vez que  $f_0$  é exatamente isto elevado ao quadrado. Podemos fazer isso para calcular as curvas de nível e o gradiente. Derivando, temos que  $\nabla f(x) = (2, 6)$ .



Indo na direção contrária ao gradiente, perpendicular as curvas de nível, chegamos ao ponto  $x^* = (1/2, 1/7)$ .

**Exercício 4.8**

Apresente uma solução explícita para cada um dos PPLs

1. Minimizando a função linear em um conjunto afim.

$$\begin{array}{ll} \min & c^\top x \\ \text{s.a.} & Ax = b \end{array}$$

2. Minimizando a função linear em um semi-espço.

$$\begin{array}{ll} \min & c^\top x \\ \text{s.a.} & a^\top x \leq b \end{array}$$

onde  $a \neq 0$ .

3. Minimizando a função linear em um retângulo.

$$\begin{array}{ll} \min & c^\top x, \\ \text{s.a.} & l \preceq x \preceq u, \end{array}$$

onde  $l$  e  $u$  satisfazem  $l \preceq u$ .

4. Minimizando a função linear em um simplex probabilístico, definido com o conjunto de vetores  $\{x \in \mathbb{R}^n : \mathbf{1}^\top x = 1, x \succeq 0\}$ .

$$\begin{array}{ll} \min & c^\top x \\ \text{s.a.} & \sum_{i=1}^n x_i = 1 \\ & x \succeq 0 \end{array}$$

Depois de resolver o problema, diga o que ocorre se a restrição de igualdade for substituída por uma inequação  $\sum_{i=1}^n x_i \leq 1$ .

5. Minimizando a função linear em uma caixa unitária com restrição de despesa total.

$$\begin{array}{ll} \min & c^\top x, \\ \text{s.a.} & \sum_{i=1}^n x_i = \alpha, \\ & 0 \preceq x \preceq 1, \end{array}$$

onde  $\alpha$  é um inteiro entre 0 e  $n$ . Depois de resolver o problema, diga o que ocorre se a restrição de igualdade for substituída por uma inequação  $\sum_{i=1}^n x_i \leq \alpha$ .

1. Minimizando a função linear em um conjunto afim.

Podemos dividir em alguns casos:

1. Se  $Ax = b$  não tiver solução, então o problema é **inviável**. Ou seja, a solução ótima é  $\infty$ .

2. Se  $c$  é ortogonal ao espaço nulo de  $A$ , então  $c$  é ortogonal ao hiperplano  $Ax = b$  (basta transladar). Note que, como o núcleo de  $A$  é um subespaço vetorial, existe seu complemento ortogonal que será exatamente a imagem de  $A^\top$ . Em outras palavras,  $c$  pertence a  $\text{Im}(A^\top)$ . Dessa forma, existe um vetor  $\lambda$  tal que

$$c = A^\top \lambda$$

Nessa situação, qualquer solução satisfazendo  $Ax = b$  resolve o problema uma vez que você não pode se mover por  $Ax = b$  de forma a decrescer  $c^\top x$ . Dessa forma, a solução ótima dada pela função objetivo será:

$$c^\top x = \lambda^\top Ax = \lambda^\top b$$

3. Se  $c$  não é ortogonal ao espaço nulo de  $A$  então a projeção de  $c$  no espaço nulo de  $A$  é uma projeção não-trivial e portanto, seguindo a direção contrária da projeção a função objetivo pode decrescer o tanto quanto for possível.

Dessa forma, a solução pode ser dividida em

$$p^* = \begin{cases} \infty & \text{if } Ax = b \text{ quando não há solução} \\ \lambda^\top b & c = A^\top \lambda \text{ para algum } \lambda \\ -\infty & \text{if } Ax = b \text{ caso contrário} \end{cases}$$

## 2. Minimizando a função linear em um semi-espaço.

Neste caso, esse problema é sempre viável. Novamente, suponha que  $c$  seja ortogonal ao espaço nulo. Dessa forma, podemos decompor  $c$  com uma componente do espaço nulo somada a uma componente da imagem de  $A^\top$ .

$$c = a\lambda + \hat{c}$$

Onde  $a^\top \hat{c} = 0$ . Vamos dividir em alguns casos

Se  $\lambda > 0$ , então podemos escolher um  $x = -ta$ , com  $t \geq 0$  fazendo  $t \rightarrow \infty$ , temos

$$c^\top x = -tc^\top a = -t\lambda a^\top a \rightarrow -\infty$$

Além disso,

$$a^\top x - b = -ta^\top a - b \leq 0$$

Logo, o problema é ilimitado inferiormente.

Se  $\hat{c} \neq 0$ , o problema também será ilimitado inferiormente. Basta escolher  $x = e$  e fazer  $t \rightarrow \infty$ .

Se  $c = \lambda a + \hat{c}$  e  $x = ba - t\hat{c}$ , então

$$\begin{aligned} c^\top x &= (\lambda a + \hat{c})^\top (ba - t\hat{c}) \\ &= \lambda ba^\top a + bc^\top a - \lambda ta^\top \hat{c} - t\hat{c}^\top \hat{c} \\ &= \lambda ba^\top a + bc^\top a - t\hat{c}^\top \hat{c} \end{aligned}$$

Como  $\lambda ba^\top a + bc^\top a$  é constante, temos que  $c^\top x \rightarrow -\infty$  quando  $t \rightarrow \infty$ .

Se  $\hat{c} = 0$ , então  $c = a\lambda$  para algum  $\lambda \leq 0$ . Logo,

$$c^\top x = \lambda a^\top x \underbrace{\geq}_{a^\top x \leq b} \lambda b$$

Logo,  $c^\top x = \lambda b$ . A solução final fica

$$p^* = \begin{cases} \lambda b & c = a\lambda \text{ para algum } \lambda \leq 0 \\ -\infty & \text{caso contrário} \end{cases}$$

## 3. Minimizando a função linear em um retângulo.

Pela estrutura do problema, podemos **separá-los**, uma vez que a função objetivo é a soma de termos  $c_i x_i$  e as restrições dependem apenas de uma única variável. Podemos resolver o problema minimizando cada componente de  $x$  independentemente. Ou seja, vamos resolver o seguinte problema

$$\begin{aligned} \min \quad & c_i x_i \\ \text{s.a} \quad & l_i \leq x_i \leq u_i \end{aligned}$$

Observe que:

- Se  $c_i > 0$ , então a solução ótima será  $x_i^* = l_i$
- Se  $c_i < 0$ , então  $x_i^* = u_i$
- se  $c_i = 0$ , então qualquer  $x_i$  no intervalo fechado  $[l_i, u_i]$  é ótimo

Dessa forma, a solução ótima do problema original pode ser escrita como

$$p^* = l^T \max\{c, 0\} + u^T \max\{-c, 0\}$$

4. Minimizando a função linear em um simplex probabilístico, definido com o conjunto de vetores

Vamos ordenar as componentes do vetor  $c$  de forma crescente.

$$c_1 = c_2 = \dots = c_k < c_{k+1} \leq \dots \leq c_n$$

Como  $c_1$  é a componente de menor valor, podemos escrever

$$\sum_{i=1}^n c_i x_i \geq c_1 \underbrace{\sum_{i=1}^n x_i}_z$$

Que será o menor valor que  $c^T x$  poderá assumir, com

$$x_1 + \dots + x_k = 1$$

Uma vez que  $k$  componentes possuem o mesmo valor e o resto das componentes

$$x_{k+1} = \dots = x_n = 0$$

Donde concluímos que  $p^* = z$ .

Para a versão de *budget*, como não temos necessariamente uma igualdade para garantir o investimento e queremos minimizar  $c^T x$ , bastará priorizar as variáveis associadas aos coeficientes  $c$  negativos. Em outras palavras,  $p^* = \min\{0, z\}$ .

5. Minimizando a função linear em uma caixa unitária com restrição de despesa total.

Novamente, vamos ordenar de forma crescente os coeficientes  $c$ .

$$c_1 \leq \dots \leq c_{i-1} < c_i = \dots = c_\alpha = \dots = c_k < c_{k+1} \leq \dots \leq c_n$$

A solução ótima será exatamente a soma dos  $\alpha$  menores valores de  $c$ , ou seja

$$c_1 + c_2 + \dots + c_\alpha$$

Com

$$x_1 = \dots = x_{i-1} = 1$$

E, considerando que há alguns elementos iguais ao elemento na posição  $\alpha$ , vamos fazer

$$x_i + \dots + x_k = \alpha - i + 1$$

Para considerar **exatamente** os  $\alpha$  variáveis associadas ao coeficientes de menor custo. E com o resto, zeramos

$$x_{k+1} = \dots = x_n = 0$$

Para o segundo caso, basta tomarmos o somatório dos valores não positivos de  $c$ . Em outras palavras, faremos  $x = 1$  toda vez que  $c_i < 0$ , não ultrapassando  $\alpha$  e 0 caso contrário.

### Exercício 4.17

Considere o problema de otimização

$$\begin{aligned} \max \quad & \sum_{j=1}^n r_j(x_j), \\ \text{s.a.} \quad & Ax \preceq c^{\max}, \\ & x \succeq 0, \end{aligned}$$

2 onde  $x \in \mathbb{R}^n$  é a variável,  $A \in \mathbb{R}^{m \times n}$  e  $c^{\max} \in \mathbb{R}^m$  são dados, e  $r_j(x_j)$  é uma função côncava linear por partes, dada por

$$r_j(x_j) = \begin{cases} p_j x_j & 0 \leq x_j \leq q_j \\ p_j q_j + p_j^{\text{disc}}(x_j - q_j) & x_j \geq q_j \end{cases}$$

onde  $p, q \succeq 0$  e  $0 < p_j^{\text{disc}} < p_j$  para todo  $j = 1, \dots, n$ . Transforme o modelo em um problema de programação linear, apresente os passos detalhadamente.

Podemos escrever a função de receita como

$$r_j(x_j) = \min_j \{p_j x_j, p_j q_j + p_j^{\text{disc}}(x_j - q_j)\}$$

Para vermos essa equivalência, considere

$$p_j x_j < p_j q_j + p_j^{\text{disc}}(x_j - q_j) \Leftrightarrow p_j(x_j - q_j) < p_j^{\text{disc}}(x_j - q_j)$$

Como  $p_j > p_j^{\text{disc}}$ , isso só será verdade se  $x_j < q_j$ . Por outro lado,

$$p_j x_j > p_j q_j + p_j^{\text{disc}}(x_j - q_j) \Leftrightarrow p_j(x_j - q_j) > p_j^{\text{disc}}(x_j - q_j)$$

Apenas se  $x_j > q_j$ .

Dessa maneira, podemos definir uma nova variável  $u_j$  que será um limite inferior para  $r_j(x_j)$ , de forma que podemos adicionar as seguintes restrições ao problema:

$$\begin{aligned} p_j x_j &\geq u_j \\ p_j q_j + p_j^{\text{disc}}(x_j - q_j) &\geq u_j \end{aligned}$$

Como no problema original estamos querendo maximizar a receita total, podemos reescrever o problema da seguinte maneira

$$\max \quad \sum_{j=1}^n u_j \tag{1}$$

$$\text{s.a.} \quad x \succeq 0 \tag{2}$$

$$Ax \preceq c^{\max} \quad \text{resource limits} \tag{3}$$

$$p_j x_j \geq u_j \tag{4}$$

$$p_j q_j + p_j^{\text{disc}}(x_j - q_j) \geq u_j \tag{5}$$

Em outras palavras, podemos crescer  $u_j$  até no máximo  $p_j x_j$  ou  $p_j q_j + p_j^{\text{disc}}(x_j - q_j) \geq u_j$ , dependendo do valor de  $x_j$ .

Agora, temos um problema de programação linear com variáveis  $x$  e  $u$ . Para mostrar que esse novo problema é equivalente ao original, vamos fixar uma solução  $x$ .

As últimas duas restrições (4-5) garantem que  $u_j \leq r_j(x_j)$ , então pra toda solução viável nesse LP, a função objetivo nos dá um valor menor ou igual a receita total. Por outro lado, sempre podemos pegar, sem perda de generalidade,  $u_j = r_j(x_j)$  que é exatamente o caso em que as duas funções se igualam.



**Exercício 4.11**

Formule os problemas a seguir como problemas de programação linear. Explique detalhadamente a relação entre a solução ótima de cada problema e a solução do seu LP equivalente. Considere  $A \in \mathbb{R}^{m \times n}$  e  $b \in \mathbb{R}^m$  dados do problema.

1. Minimizar  $\|Ax - b\|_\infty$
2. Minimizar  $\|Ax - b\|_1$
3. Minimizar  $\|Ax - b\|_1$  sujeito a  $\|x\|_\infty \leq 1$
4. Minimizar  $\|x\|_1$  sujeito a  $\|Ax - b\|_\infty \leq 1$
5. Minimizar  $\|Ax - b\|_1 + \|x\|_\infty$

$$\boxed{\text{Minimizar } \|Ax - b\|_\infty}$$

Por definição, temos que  $\|Ax - b\|_\infty = \max_i |Ax_i - b_i|$ . Com isso, podemos criar uma nova variável  $u$  que será um limitante superior para  $Ax - b$ , ao passo que minimizamos  $u$ , descobrindo assim o maior valor para  $Ax - b$ . No entanto, como estamos lidando com módulo, também será necessário que  $Ax - b$  esteja limitando inferiormente pelo simétrico de  $u$ .

Formalmente, seja  $u \in \mathbb{R}$ , o novo LP pode ser reescrito como

$$\min \quad u \tag{6}$$

$$\text{s.a.} \quad Ax - b \preceq u \tag{7}$$

$$Ax - b \succeq -u \tag{8}$$

Agora, basta provarmos a equivalência. Para um  $x$  fixado as restrições 7 e 8 podem ser escritas, para algum  $k$ ,

$$\begin{aligned} -u \leq a_k^\top x - b_k \leq u &\Leftrightarrow u \geq |a_k^\top x - b_k| \\ &\Leftrightarrow u \geq \max_k |a_k^\top x - b_k| \\ &\Leftrightarrow u \geq \|Ax - b\|_\infty \end{aligned}$$

Fazendo para todo  $x$ , chegamos no resultado minimizando  $u$ .

$$\boxed{\text{Minimizar } \|Ax - b\|_1}$$

Usaremos a mesma ideia, no entanto, como não estamos olhando para o valor máximo, a dimensão de  $u$  deverá ser modificada. Considere  $u \in \mathbb{R}^m$ , podemos reescrever como seguinte LP:

$$\begin{aligned} \min \quad & \sum_{i=1}^m u_i \\ \text{s.a.} \quad & Ax - b \preceq u \\ & Ax - b \succeq -u \end{aligned}$$

Agora, provemos a equivalência. Para um  $x$  fixado arbitrário, as restrições adicionais podem ser escritas como

$$-u_k \leq a_k^\top x - b_k \leq u_k \Leftrightarrow u_k \geq |a_k^\top x - b_k|$$

Observe que atingimos o ótimo com relação a  $u$  escolhendo exatamente  $u_k = |a_k^\top x - b_k| = \|Ax - b\|_1$ . Fazendo para todo  $x$ , chegamos no resultado.

$$\boxed{\text{Minimizar } \|Ax - b\|_1 \text{ sujeito a } \|x\|_\infty \leq 1}$$

Equivalente ao que fizemos anteriormente,

$$\begin{aligned} \min \quad & \sum_{i=1}^m u_i \\ \text{s.a} \quad & Ax - b \preceq u \\ & Ax - b \succeq -u \\ & x \leq 1 \\ & x \geq -1 \end{aligned}$$

$$\boxed{\text{Minimizar } \|x\|_1 \text{ sujeito a } \|Ax - b\|_\infty \leq 1}$$

Equivalente ao que fizemos anteriormente,

$$\begin{aligned} \min \quad & \sum_{i=1}^m u_i \\ \text{s.a} \quad & Ax - b \preceq 1 \\ & Ax - b \succeq -1 \\ & x \leq u \\ & x \geq -u \end{aligned}$$

$$\boxed{\text{Minimizar } \|Ax - b\|_1 + \|x\|_\infty}$$

Para esta, vamos definir uma variável para cada componente da soma.

$$\begin{aligned} \min \quad & \sum_{i=1}^m u_i + t \\ \text{s.a} \quad & Ax - b \preceq u \\ & Ax - b \succeq -u \\ & x \leq \sum_{i=1}^m t \\ & x \geq \sum_{i=1}^m -t \end{aligned}$$

**Exercício adicional 4.1**

Encontre condições necessárias e suficientes para  $x \in \mathbb{R}^n$  minimizar a função convexa e diferenciável  $f$  no conjunto  $\{x \in \mathbb{R}^n \mid \sum_{i=1}^n x_i = 1, x_i \geq 0\}$ .

Considere o conjunto

$$R = \{x \in \mathbb{R}^n \mid \sum_{i=1}^n x_i = 1, x_i \geq 0\}$$

Pelas condições de otimalidade sabemos que se  $x$  é viável então  $\nabla f(x)^\top (y - x) \geq 0$  para todo  $y$  viável.

Afirmção:

$$\nabla f(x)^\top (y - x) \geq 0 \Rightarrow \min_{i=1, \dots, n} \nabla f(x)_i \geq \nabla f(x)^\top x$$

Demonstração: Por hipótese, temos que vale  $\nabla f(x)^\top (y - x) \geq 0$  para todo  $y$  viável, em particular, tome  $y = e_i$ , onde  $e_i$  é o vetor canônico. Dessa forma, temos

$$\begin{aligned} \nabla f(x)^\top (y - x) \geq 0 &\Leftrightarrow \nabla f(x)_i \underbrace{y}_{e_i} - \nabla f(x)^\top x \geq 0 \\ &\Leftrightarrow \nabla f(x)_i \geq \nabla f(x)^\top x \end{aligned}$$

■

Afirmção:

$$\min_{i=1, \dots, n} \nabla f(x)_i \geq \nabla f(x)^\top x \Rightarrow \nabla f(x)^\top (y - x) \geq 0$$

Demonstração: Seja  $y$  um ponto viável, temos por hipótese que para todo  $i = 1, \dots, n$  vale

$$\nabla f(x)_i \geq \nabla f(x)^\top x$$

Multiplicando ambos os lados por  $y_i$  e somando, temos

$$\underbrace{\sum_{i=1}^n y_i \nabla f(x)_i}_{y^\top \nabla f(x)} \geq \underbrace{\sum_{i=1}^n y_i \nabla f(x)^\top x}_{=1} = \nabla f(x)^\top x$$

Logo

$$y^\top \nabla f(x) \geq \nabla f(x)^\top x \Leftrightarrow \nabla f(x)^\top (y - x) \geq 0$$

Reescrevendo,

$$\min_{i=1, \dots, n} \nabla f(x)_i \geq \nabla f(x)^\top x \Leftrightarrow \min_{i=1, \dots, n} \frac{\partial f}{\partial x_i} \geq \sum_{i=1}^n x_i \frac{\partial f}{\partial x_i}$$

Como  $\sum_{i=1}^n x_i = 1$  e  $x_i \geq 0$ , temos

$$\min_{i=1, \dots, n} \frac{\partial f}{\partial x_i} \leq \sum_{i=1}^n x_i \frac{\partial f}{\partial x_i}$$

O que nos dá que

$$\min_{i=1, \dots, n} \frac{\partial f}{\partial x_i} = \sum_{i=1}^n x_i \frac{\partial f}{\partial x_i}$$

Isso só é possível se quando  $\frac{\partial f}{\partial x_k} > \min_i \frac{\partial f}{\partial x_i}$ , para algum  $k$ ,  $x_k = 0$ . Além disso, se  $x_k > 0$  então  $\frac{\partial f}{\partial x_k} = \min_{i=1,\dots,n} \frac{\partial f}{\partial x_i}$ . ■

### Exercício adicional 5.1

Considere a matriz  $X = X^\top \in \mathbb{R}^{m+n \times m+n}$  particionada como

$$X = \begin{bmatrix} A & B \\ B^\top & C \end{bmatrix}$$

onde  $A \in \mathbb{R}^{n \times n}$ . Se  $\det(A) \neq 0$ , a matriz  $S = C - B^\top A^{-1} B$  é chamada de complemento de Schur de  $A$  em  $X$ .

1. O complemento de Schur aparece quando se minimiza uma função na forma quadrática em alguma das variáveis. Seja

$$f(u, v) = \begin{bmatrix} u^\top & v^\top \end{bmatrix} X \begin{bmatrix} u^\top & v^\top \end{bmatrix}^\top$$

onde  $u \in \mathbb{R}^n$ . Seja  $g(v)$  o menor valor de  $f$  em  $u$ , ou seja,  $g(v) = \inf_u f(u, v)$ . Veja que  $g(v)$  pode ser  $-\infty$ . Mostre que se  $A \succ 0$ , temos  $g(v) = v^\top S v$ .

2. O complemento de Schur aparece em diversas caracterizações de matrizes semi-definidas positivas e definidas positivas de uma matriz em blocos. Mostre que:

(a)  $X \succ 0$  se e somente se  $A \succ 0$  e  $S \succ 0$ .

(b) Se  $A \succ 0$ , então  $X \succeq 0$  se e somente se  $S \succeq 0$ .

(c)  $X \succeq 0$  se e somente se  $A \succeq 0$ ,  $B^\top (I - AA^\dagger) = 0$  e  $C - B^\top A^\dagger B \succeq 0$ , onde  $A^\dagger$  é a pseudo-inversa de Moore-Penrose de  $A$ . ( $C - B^\top A^\dagger B$  serve como generalização do complemento de Schur no caso em que  $A$  é singular e semi-definida positiva).

Afirmção: Se  $A \succ 0$ , temos  $g(v) = v^\top S v$ .

Temos que

$$f(u, v) = u^T A u + 2v^T B u + v^T C v$$

Por hipótese,  $A \succ 0$ , então podemos minimizar  $f$  com relação a  $u$  calculando o gradiente em relação a  $u$  e igualando a zero.

Pela definição, temos que

$$\alpha = u^T A u = \sum_{j=1}^n \sum_{i=1}^n a_{ij} u_i u_j$$

Derivando  $\alpha$  com respeito ao  $k$ -ésimo elemento de  $u$ , temos

$$\frac{\partial \alpha}{\partial u_k} = \sum_{j=1}^n a_{kj} u_j + \sum_{i=1}^n a_{ik} u_i$$

Fazendo para todo  $k = 1, 2, \dots, n$ , temos

$$\frac{\partial \alpha}{\partial u} = u^T A^T + u^T A = u^T (A^T + A)$$

Como as matrizes são simétricas então

$$\frac{\partial \alpha}{\partial u} = 2u^T A$$

Agora, derivando  $\beta = 2v^T B u$  com respeito a  $u$ , temos que

$$\frac{\partial \beta}{\partial u} = 2v^T B$$

Logo, a derivada de  $f$  com respeito a  $u$  será

$$\frac{\partial f}{\partial u} = 2u^T A + 2v^T B$$

Igualando a zero, temos que

$$\begin{aligned} 2u^T A + 2v^T B &= 0 \\ 2u^T A &= -2v^T B \\ u^T A &= -v^T B \\ u^T &= -v^T B A^{-1} \\ u &= -A^{-1} B v \end{aligned}$$

Agora, substituindo em  $f$ , temos

$$f(u^*, v) = g(v) = -(A^{-1} B v)^T A (-A^{-1} B v) + 2v^T B (-A^{-1} B v) + v^T C v$$

Arrumando, temos

$$v^T B^T A^{-1} \underbrace{A A^{-1}}_{=1} B v - 2v^T B A^{-1} B v + v^T C v$$

Botando  $v^T$  e  $v$  em evidência, temos

$$v^T (B^T A^{-1} B - 2 \underbrace{B}_{B=B^T} A^{-1} B v + C) v = v^T (C - B^T A^{-1} B) v = v^T S v$$

Afirmção:  $(\Rightarrow)$  Se  $X \succ 0$  então  $A \succ 0$  e  $S \succ 0$ .

Demonstração: Como  $X \succ 0$  então  $f(u, v) > 0$  para todo vetor não nulo  $(u, v)$ . Em particular, se pegarmos  $f(u, 0) = u^T A u > 0$  para todo vetor não nulo  $u$ . Dessa forma,  $A \succ 0$ .

Pela questão anterior, podemos usar o ponto  $u^* = -A^{-1} B v$  para analisar o que acontece com  $S$ . Com isso,  $f(u^*, v) = v^T (C - B^T A^{-1} B) v > 0$ , dessa forma,  $S = C - B^T A^{-1} B \succ 0$  ■

Afirmção:  $(\Leftarrow)$  Se  $A \succ 0$  e  $S \succ 0$  então  $X \succ 0$

Demonstração: Segue da questão anterior que

$$f(u, v) \geq f(u^*, v) = v^T S v > 0 \quad \because S \succ 0$$

Se  $v \neq 0$ . Por outro lado, se  $v = 0$  e  $u \neq 0$

$$f(u, 0) = u^T A u > 0 \quad \because A \succ 0$$

Logo,  $f(u, v) > 0$  e consequentemente,  $X \succ 0$ . ■

Afirmção:  $(\Rightarrow)$  Se  $A \succ 0$  (logo  $X \succeq 0$ ) então  $S \succeq 0$ .

Demonstração: Por hipótese,  $X \succ 0$ , isto é,  $f(u, v) \geq 0$  para todo  $u, v$ . Em particular, valerá para  $f(u^*, v)$  que é exatamente  $v^T S v$ . Dessa forma,  $S \succeq 0$ . ■

Afirmção:  $(\Leftarrow)$   $S \succeq 0$  então  $A \succ 0$  (logo  $X \succeq 0$ ).

Demonstração: Pelo item anterior, sabemos que se  $A \succ 0$  então  $f(u^*, v) = v^T S v$ . Como por hipótese  $S \succ 0$  então

$$f(u, v) \geq f(u^*, v) = v^T S v \geq 0$$

Para todo  $u, v$ . Dessa forma,  $X \succ 0$  e por consequência,  $A \succ 0$ . ■

---

Afirmção:  $X \succeq 0$  se e somente se  $A \succeq 0, B^T (I - AA^\dagger) = 0$  e  $C - B^T A^\dagger B \succeq 0$

Demonstração:

Vamos supor que  $A \in \mathbb{R}^{k \times k}$  tem  $\text{rank}(A) = r$ . Dessa forma, existem matrizes  $Q_1 \in \mathbb{R}^{k \times r}$  e  $Q_2 \in \mathbb{R}^{k \times (k-r)}$  e uma matriz diagonal invertível  $\Lambda \in \mathbb{R}^{r \times r}$  de tal forma que podemos decompor  $A$  da seguinte maneira

$$A = \begin{bmatrix} Q_1 & Q_2 \end{bmatrix} \begin{bmatrix} \Lambda & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} Q_1 & Q_2 \end{bmatrix}^T$$

Onde  $\begin{bmatrix} Q_1 & Q_2 \end{bmatrix}^T \begin{bmatrix} Q_1 & Q_2 \end{bmatrix} = I$   $\because$  ortogonalidade.  
Essa é a decomposição espectral de  $A$ .

Considere a seguinte matriz

$$M = \begin{bmatrix} \underbrace{Q_1}_{(n-k) \times r} & \underbrace{Q_2}_{(n-k) \times (k-r)} & \underbrace{\begin{bmatrix} 0 \\ I \end{bmatrix}}_{(n-k) \times (n-k)} \end{bmatrix} \in \mathbb{R}^{n \times n}$$

Que é **não-singular** uma vez que

$$\begin{bmatrix} Q_1 & Q_2 & 0 \\ 0 & 0 & I \end{bmatrix} \cdot \begin{bmatrix} Q_1 & 0 \\ Q_2 & 0 \\ 0 & I \end{bmatrix} = \begin{bmatrix} I & 0 \\ 0 & I \end{bmatrix} = I$$

Agora, como  $X$  é semi-definida positiva, vale

$$\begin{bmatrix} A & B \\ B^T & C \end{bmatrix} \succeq 0 \Leftrightarrow \begin{bmatrix} Q_1 & Q_2 & 0 \\ 0 & 0 & I \end{bmatrix}^T \begin{bmatrix} A & B \\ B^T & C \end{bmatrix} \begin{bmatrix} Q_1 & Q_2 & 0 \\ 0 & 0 & I \end{bmatrix} \succeq 0$$

$$\begin{bmatrix} Q_1 & Q_2 & 0 \\ 0 & 0 & I \end{bmatrix}^T \begin{bmatrix} A & B \\ B^T & C \end{bmatrix} = \begin{bmatrix} [Q_1 Q_2]^T A & [Q_1 Q_2]^T B \\ B^T & C \end{bmatrix} =$$

Dai

$$\begin{bmatrix} [Q_1 Q_2]^T A & [Q_1 Q_2]^T B \\ B^T & C \end{bmatrix} \begin{bmatrix} Q_1 & Q_2 & 0 \\ 0 & 0 & I \end{bmatrix} = \begin{bmatrix} [Q_1 Q_2]^T A [Q_1 Q_2] & [Q_1 Q_2]^T B \\ B^T [Q_1 Q_2] & C \end{bmatrix}$$

$$\Leftrightarrow \begin{bmatrix} \Lambda & 0 & Q_1^T B \\ 0 & 0 & Q_2^T B \\ B^T Q_1 & B^T Q_2 & C \end{bmatrix} \succeq 0$$

$$\Leftrightarrow Q_2^T B = 0, \begin{bmatrix} \Lambda & Q_1^T B \\ B^T Q_1 & C \end{bmatrix} \succeq 0.$$

Temos que  $\Lambda \succ 0$  se e somente se  $A \succeq 0$ .

É verdade que

$$A^\dagger = Q_1 \Lambda^{-1} Q_1^T, \quad I - AA^\dagger = Q_2 Q_2^T.$$

Dessa forma,

$$Q_2^T B = 0 \Leftrightarrow Q_2 Q_2^T B = (I - A^\dagger A) B = 0$$

Além disso, como  $\Lambda$  é invertível,

$$\begin{bmatrix} \Lambda & Q_1^T B \\ B^T Q_1 & C \end{bmatrix} \succeq 0 \Leftrightarrow \Lambda \succ 0, \quad C - B^T Q_1 \Lambda^{-1} Q_1^T B = C - B^T A^\dagger B \succeq 0.$$

■

**Exercício 1.1**

Considere a matriz  $X = X^\top \in \mathbb{R}^{m+n \times m+n}$  particionada como

$$X = \begin{bmatrix} A & B \\ B^\top & C \end{bmatrix}$$

onde  $A \in \mathbb{R}^{n \times n}$ . Se  $\det(A) \neq 0$ , a matriz  $S = C - B^\top A^{-1} B$  é chamada de complemento de Schur de  $A$  em  $X$ .  
1. Reconhecer complementos de Schur normalmente ajuda a representar restrições convexas não-lineares como inequações lineares de matrizes (LMI). Considere a função

$$f(x) = (Ax + b)^\top (P_0 + x_1 P_1 + \dots + x_n P_n)^{-1} (Ax + b),$$

onde  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^m$  e  $P_i = P_i^\top \in \mathbb{R}^{m \times m}$ , com o domínio

$$\text{dom } f = \{x \in \mathbb{R}^n \mid P_0 + x_1 P_1 + \dots + x_n P_n \succ 0\}.$$

Essa é a composição da função fracionária da matriz e um mapeamento afim, e então é uma função convexa. Dada uma representação LMI de  $\text{epi } f$ , encontre a matriz simétrica  $F(x, t)$  afim em  $(x, t)$ , tal que

$$x \in \text{dom } f, \quad f(x) \leq t \iff F(x, t) \succeq 0.$$

O *epigrafo* de  $f$  é definida como

$$\text{epi } f = \{(x, P, t) \mid P \succ 0, x^\top P^{-1} x \leq t\}$$

Onde  $P = P_0 + x_1 P_1 + \dots + x_n P_n$ . Da outra questão, provamos que

$$\text{Se } A \succ 0, \text{ então } X \succeq 0 \text{ se e somente se } S \succeq 0.$$

Como  $P \succ 0$ , podemos definir  $X$  como

$$X = \begin{bmatrix} P & Ax + b \\ (Ax + b)^\top & t \end{bmatrix} \succ 0$$

Que é uma matriz simétrica afim em  $(x, t)$ .



### Exercício 1.1

Formule o problema de otimização como problema de programação semidefinida. A variável é  $x \in \mathbb{R}^n$  e  $F(x)$  é definida como

$$F(x) := F_0 + x_1 F_1 + x_2 F_2 + \cdots + x_n F_n,$$

com  $F_i \in \mathbb{S}^m$ , para  $i = 1, \dots, n$ . O domínio de  $f$  em cada subproblema é dado por  $\text{dom } f = \{x \in \mathbb{R}^n \mid F(x) \succ 0\}$ .

1. Minimizar  $f(x) = c^\top F(x)^{-1}c$ , onde  $c \in \mathbb{R}^m$ .
2. Minimizar  $f(x) = \max_{i=1, \dots, K} c_i^\top F(x)^{-1}c_i$ , onde  $c_i \in \mathbb{R}^m, i = 1, \dots, K$ .
3. Minimizar  $f(x) = \sup_{\|c\|_2 \leq 1} c^\top F(x)^{-1}c$ .

Considere a matriz  $X = X^\top \in \mathbb{R}^{m+n \times m+n}$  particionada como

$$X = \begin{bmatrix} A & B \\ B^\top & C \end{bmatrix}$$

onde  $A \in \mathbb{R}^{n \times n}$ . Se  $\det(A) \neq 0$ , a matriz  $S = C - B^\top A^{-1}B$  é chamada de complemento de Schur de  $A$  em  $X$ .

Minimizar  $f(x) = c^\top F(x)^{-1}c$ , onde  $c \in \mathbb{R}^m$ .

Considere a seguinte matriz

$$X = \begin{bmatrix} F(x) & c \\ c^\top & t \end{bmatrix} \succeq 0$$

Como  $F(x) \succ 0$ , pela demonstração da questão anterior,  $X \succeq 0$  e então  $S \succeq 0$ , onde  $S$  é o complemento de Schur de  $A$  em  $X$ . Daí, segue que

$$S = t - c^\top F^{-1}(x)c \succ 0 \Leftrightarrow t \succ c^\top F^{-1}(x)c$$

Dessa forma, podemos reescrever o problema como

$$\begin{array}{ll} \min & t \\ \text{s.a.} & \begin{bmatrix} F(x) & c \\ c^\top & t \end{bmatrix} \succeq 0. \end{array}$$

Minimizar $f(x) = \max_{i=1,\dots,K} c_i^\top F(x)^{-1} c_i$ , onde $c_i \in \mathbb{R}^m, i = 1, \dots, K$ .
---

Nesse caso, podemos usar a mesma ideia do item anterior, com a diferença que podemos definir  $K$  matrizes  $X$ , uma para cada  $i$ . Depois disso, podemos adicioná-las como  $K$  restrições no nosso problema, de forma que encontraremos o menor  $t$  que faz com que todas as matrizes definidas independentemente sejam menor do que  $t$ .

$$\begin{aligned}
& \text{minimize} && t \\
& \text{subject to} && \begin{bmatrix} F(x) & c_i \\ c_i^T & t \end{bmatrix} \succeq 0, \quad i = 1, \dots, K. \\
& && t - c_i^t F^{-1}(x) c_i \succ 0 \Leftrightarrow t \succ c_i^t F^{-1}(x) c_i \quad \forall i = 1, \dots, K
\end{aligned}$$

$$\boxed{\text{Minimizar } f(x) = \sup_{\|c\|_2 \leq 1} c^\top F(x)^{-1} c.}$$

Segue da definição de autovalores e autovetores que

$$F^{-1}(x)c = \lambda c \Leftrightarrow \sup_{\|c\|=1} c^\top F^{-1}(x)c = \lambda_{\max}(F^{-1}(x))$$

Onde  $c$  são os autovetores associados aos autovalores  $\lambda$ . Dessa forma, considere a seguinte matriz

$$X = \begin{bmatrix} F(x) & I \\ I & tI \end{bmatrix} \succeq 0.$$

Como  $F(x) \succ 0$ , pela demonstração da questão anterior,  $X \succeq 0$  e então  $S \succeq 0$ , onde  $S$  é o complemento de Schur de  $A$  em  $X$ . Daí, segue que

$$S = tI - F^{-1}(x) \succ 0 \Leftrightarrow tc^\top Ic - c^\top F^{-1}(x)c \succ 0 \Leftrightarrow t \succ c^\top F^{-1}(x)c$$

Dessa forma, podemos reescrever o problema como

$$\begin{array}{ll} \min & t \\ \text{s.a.} & \begin{bmatrix} F(x) & I \\ I & tI \end{bmatrix} \succeq 0. \end{array}$$